HW2 Sentiment Analysis

0813458 資財 簡辰穎

—. Import Library + Load Data

Import library

Load Data



__. Data Prepocessing

a. 讀取 csv 檔並僅保留 stars, text 兩個欄位



- b. 將 stars 內大於等於 4 的轉成 1, 其餘轉成 0
 - (1 代表 positive 0 代表 negative)
- c. 將 text 中的文字全部轉成小寫 (對於 stop words 處理有差別)



d. 去除停頓詞(stop words)

常見去除停頓詞的方法有:

- Spacy / nltk / sklearn / 自定義停頓詞

我選擇使用 Spacy 來處理停頓詞·首先先看一下 Spacy 中的英文停頓詞詞庫大

概有哪些英文詞

```
b. 去除停頓詞 (Stop Words) 的定義上是兩個集合:

1. 這個語言中出現非常頻繁的詞。
2. 文本資料中出現非常頻繁的詞。

網路上有3種做法:
a. spaCy
b. nltk
c. sklearn

In [3]: #用 Python NLP 中的 spacy 維行stopwords 處理
#光著一下spacy 中方思史學報题
nlp = spacy.load('en_core_web_sm')
spacy_stopwords = spacy.load('en_core_web_sm')
spacy has 326 stop words are {}'.format(list(spacy_stopwords)[:20]))
spaCy has 326 stop words
The first twenty stop words are ["'d", 'nothing', 'why', 'once', 'who', 'say', 'anyone', 'nowhere', 'nobody', 'therefore', 'a
n', 'enough', 'therein', 'nor', 'whereby', 'five', 'that', 'this', 'whither']
```

接著開始去除停頓詞,將 text 切割跟 Spacy 詞庫內的詞作比較,留下沒有在 詞庫的字。可以發現去除停頓詞後 text 變得比較簡潔,對於模型的預測可能會 較準確。

- e. 文字探勘前處理,將文字轉換成向量(使用 tf-idf 與 word2vec 並比較)
 - → Tf-idf: 包含詞頻(tf)與逆向文件頻率(idf), 詞頻指某一個特定詞語在該文件中出現的頻率, 而逆向文件頻率用來處理常用字的問題

 Tf-idf = tf*idf
 - → Word2vec: 透過學習大量文本資料,將字詞用數學向量的方式來代表他們的語意。並將字詞嵌入到一個空間後,讓語意相似的單字可以有較近的距離。 主要有 CBOW 與 Skip-gram 兩種模型。從直觀上來理解, Skip-gram 是給定輸入字詞後,來預測上下文; CBOW 則是給定上下文,來預測輸入的字詞

A. Tf-idf

```
Tf-idf
In [17]: # td-idf
#vectorizer = CountVectorizer(stop_words = spacy_stopwords)
    tfidf_vectorizer = TfidfVectorizer()
    tfidf = tfidf_vectorizer.fit_transform(df1['rmsw_text'])
    weight = tfidf.toarray()
    print(weight.shape)
    print(weight)
    df1['tfidf'] = tfidf

    (10000, 29160)
    [[0. 0. 0. ... 0. 0. 0.]
    [[0. 0. 0. ... 0. 0. 0.]
    [[0. 0. 0. ... 0. 0. 0.]
    [[0. 0. 0. ... 0. 0. 0.]
    [[0. 0. 0. ... 0. 0.]
    [[0. 0. 0. ... 0. 0.]
    [[0. 0. 0. ... 0. 0.]
    [[0. 0. 0. ... 0. 0.]
    [[0. 0. 0. ... 0. 0.]
    [[0. 0. 0. ... 0. 0.]
    [[0. 0. 0. ... 0. 0.]]
```

B. Word2vec

可以看到跟 bad 相關的詞可能有 ruined, terrible, negative...的負面詞

但我們的資料是一整個評論而非單單僅是單詞,所以需要想辦法使用

word2vec 模型中的詞向量為整個評論創建向量表示

→ 解決方法: 取評論中所有詞向量的平均,對資料中的所有評論重複相同的過程獲得它們的向量

→得到每一個評論的向量並轉成 array 的形式

```
In [27]: def word_vector(tokens, size):
    vec = np.zeros(size).reshape((1, size))
    count = 0
    for word in tokens:
        try:
        vec += model_w2v.wv[word].reshape((1, size))
        count += 1.
        except KeyError: # handLing the case where the token is not in vocabulary
        continue
    if count != 0:
        vec /= count
    return vec

In [28]: wordvec_arrays = np.zeros((len(tokenized_tweet), 100))
    for i in range(len(tokenized_tweet)):
        wordvec_arrays[i,:] = word_vector(tokenized_tweet[i], 100)
        wordvec_df.shape
        print(len(wordvec_arrays))
        # wordvec_df.shape
        print(len(wordvec_arrays))
```

三. Create model

a. 先用 random forest tree 單純跑一次看看

```
Create Model

a. 使用 Random forest進行分類

In [33]: y=dfl['stars']
x=tfidf
x_train,x_test,y_train,y_test=train_test_split(x,y,random_state=42,test_size=0.2)

In [34]: rf= RandomForestClassifier(criterion= 'entropy', max_depth= None, max_features= 'sqrt', n_estimators= 500, oob_score = True)
y_pred= rf,readic(x_test)
accuracy_score(y_pred_v_test)
#先星段節一天記試着

Out[34]: 0.7995
```

b. 用套件先試試看跑 K-fold cross validation 準確度

```
In [32]: #先用套件路路看效果
from sklearn.model_selection import cross_val_score
x = tfidf
y = df1['stars']
#rf= RandomForestClassifier(criterion= 'entropy', max_depth= None, max_features= 'sqrt', n_estimators= 100, oob_score = True)
rf = RandomForestClassifier(criterion= 'entropy', max_features= 'sqrt', n_estimators= 500, oob_score = True)
accuracy = cross_val_score(rf, x, y, cv=4, scoring='accuracy')
print(accuracy)
print(accuracy)
print(accuracy.mean()*100,'%')
[8.7808 0.7944 0.7884 0.7944]
78.95 %
```

c. 建立 cross_validation_split,切割等等要丟入 K-fold cross-validation function 中的

train data 與 test data

d. 建立 K-fold cross-validation function · 並將 tf-idf 處理的 rmsw_text(remove stop words 後的 text)與 word2vec 處理的 rmsw_text 分別丟入 model

結果比較: tf-idf 跑出來的結果相較於 word2vec 好

(執行多次結果都是這樣)